

实验一：Linux 文本处理命令与测序数据 FastQC 质量控制

一、实验目的

- 1.掌握 Linux 系统中常用文本处理命令 (head、sed、awk) 及 Shell 脚本的编写方法。
- 2.学会使用 FastQC 对高通量测序数据进行质量评估，并能根据报告判断数据存在的问题及解决方案。
- 3.理解基因差异表达分析结果的基本结构与生物学含义。

二、实验内容与方法

2.1 基因表达数据处理

以植物胁迫处理后基因表达变化分析文件 gfold_expression.txt 为输入，其中第三列 GFOLD(0.01)表示差异表达的倍数变化 (>0 上调，<0 下调，=0 无显著变化)。

依次完成以下操作：

- 用 head 命令提取前 9 行，保存为 fanxinlan_gfold.head;
- 用 sed 命令删除前 9 行（即删除注释/标题部分），保留数据行，输出为 fanxinlan_gfold_expression2.txt;
- 用 awk 命令从结果文件中提取 GeneName、GFOLD(0.01)和 1stRPKM 三个字段，保存为 fanxinlan_gfold_expression3.txt;
- 用 awk 按 GFOLD 值的正负将基因分为上调和下调两组，分别输出到 fanxinlan_gfold_up.txt 和 fanxinlan_gfold_down.txt（保留标题行）；
- 用 awk 分别计算上调和下调基因的数目及 1stRPKM 平均值，并将统计结果写入 fanxinlan_statistics.txt。
- 将所有上述步骤整合为一个可重复执行的 Shell 脚本 gfold_statistics.sh。

2.2 测序数据质量评估

使用 FastQC 对两个测序数据文件进行质量检测：

- 文件一：SRR4090085_1.fq.gz.tar (Illumina 短读长测序，读长 150 bp)；

- 文件二：hifi_reads_20000.bam.fq (PacBio HiFi 长读长测序，读长 8,294-28,131 bp) 。

对生成的 HTML 报告进行解读，重点关注碱基质量、GC 含量、序列重复水平、过表达序列、接头污染等模块。

三、实验结果

3.1 基因表达文本处理结果

成功生成以下结果文件：

- fanxinlan_gfold.head—原始文件前 9 行；
- fanxinlan_gfold_expression2.txt—去除前 9 行的数据部分；
- fanxinlan_gfold_expression3.txt—仅含 GeneName、GFOLD(0.01)、1stRPKM 三列；
- fanxinlan_gfold_up.txt—上调表达基因列表；
- fanxinlan_gfold_down.txt—下调表达基因列表；
- fanxinlan_statistics.txt—上/下调基因数目及 1stRPKM 平均值。

脚本 gfold_statistics.sh 可一键复现全部输出，验证了文本处理流程的自动化与准确性。

3.2 FastQC 质量评估结果

(1) Illumina 短读长数据 (SRR4090085_1)

- **碱基质量**：读长 130 bp 以内碱基质量普遍高于 Q28，但 130 bp 以后质量明显下降（25%分位数降至 Q20 以下），呈现典型的“尾部衰减”。
- **碱基含量**：前 8 bp 和后 8 bp 存在剧烈波动，指示固定引物或 barcode 残留；中间区域 GC 含量比 AT 高约 20%，为模板本身高 GC 特征，非污染。
- **GC 含量分布**：整体分布轻微左偏，两个微小尖峰提示少量高表达片段。
- **序列重复水平**：去冗余后仍保留 84.09%，重复序列平滑下降，未见接头二聚体污染。

- **过表达序列**：有两条序列分别占总 reads 的约 2%，未与已知接头数据库匹配，可能为高表达基因片段或污染。
 - **接头含量**：Illumina 通用接头比例极低，但 poly-A 和 poly-C 信号明显，提示建库中存在加尾或引物设计偏好。
- 总体评估：该短读长文库质量较好，但需修剪前端固定引物/接头、切除尾部低质量区域，并过滤 poly-A/C 尾，重新运行 FastQC 验证方可进入下游分析。

(2) PacBio HiFi 长读长数据 (hifi_reads_20000)

- **碱基质量**：全读长位点质量几乎全部高于 Q40（错误率<0.01%），中位数和平均值均极为平稳，表现出 HiFi reads 的高准确度。
 - **碱基含量**：前 8 bp 和后 8 bp 同样出现波动，且中间区域 AT 含量较 GC 高约 20%，与 Basic Statistics 中 37% 的 GC 含量相吻合，表明模板本身为 AT 富集型（如 cDNA 或 AT-rich 病毒基因组）。
 - **GC 含量分布**：与理论分布严重偏离，呈多尖峰状，且平均 GC 比理论值低 1-3%，这并非测序错误，而是由于数据量极小（仅 500 条 reads）且序列长度离散，本质上为“克隆池”或“扩增子池”样本，而非随机基因组碎片。
 - **序列长度分布**：读长在 8-28 kb 之间呈多峰分布（如出现 14,999 bp、16,499 bp 等），说明样本经过切胶选长或长 PCR 产物混合，非随机打断。
 - **重复水平与过表达序列**：>10 次以上重复的 reads 占比极低，过表达序列种类多但每条计数仅 1-2，最大占比 0.4%，同样指向低深度混合样本。
 - **接头**：未见 Illumina 接头，但 poly-A 比例高达 45%，poly-C 约 12%，为模板固有的 poly-A 尾和引物/环化引入的 C-tail。
- 总体评估：虽单碱基质量极高，但该数据集复杂度极低、深度不足，不能用于定量或变异位点频率分析，仅适合做组装可行性测试或引物/加尾验证。处理时需对同聚物尾进行修剪，并酌情过滤过短或过长序列。

四、讨论与结论

通过本实验，熟练掌握了 Linux 下利用命令行工具对结构化文本进行筛选、统计和自动化处理的方法，这在日常生信分析中极为关键。同时，通过对两种不同平台测序数

据的 FastQC 结果解读，明确区分了“文库质量良好但需修剪”与“数据外表质量高但内在复杂度不足”两类问题，进一步理解了测序数据质控不能仅看单碱基质量，还须结合 GC 分布、重复水平、长度分布等综合判断。