

基因组组装工具性能比较分析报告

实验概述

本实验旨在比较不同基因组组装工具（**wtdbg2** 和 **hifiasm**）在处理不同类型测序数据（**CLR** 和 **CCS**）时的表现差异。通过系统的性能评估，为基因组组装项目中的工具选择提供数据支持。

1. 材料与方法

1.1 实验数据

- 参考基因组**: 大肠杆菌 (Escherichia coli), 长度 4,641,652 bp
- 测序数据**: PacBio CLR 数据 (连续长读长)、PacBio CCS 数据 (环形一致性序列)

1.2 分析工具

- wtdbg2** v2.5 - 基于模糊 Bruijn 图的快速组装工具
- hifiasm** v0.16 - 基于重叠图的高精度组装工具
- QUAST** v5.3 - 组装质量评估工具

1.3 实验设计

三组对比实验设计

- wtdbg2 + CLR 数据 → 评估工具在长读长高错误率数据表现
- wtdbg2 + CCS 数据 → 评估工具在高精度数据表现
- hifiasm + CCS 数据 → 评估不同算法在相同数据表现

2. 结果与分析

2.1 组装连续性对比

关键发现：数据质量对组装连续性影响显著大于算法选择

评估指标	wtdbg2+CLR	wtdbg2+CCS	hifiasm+CCS
Contig 数量	166	1	1
N50 长度(bp)	9,903	4,639,873	4,665,559
最长 Contig(bp)	37,015	4,639,873	4,665,559

分析：

- CCS 数据显著提升组装连续性，两种工具均获得单 contig 结果
- CLR 数据受高错误率限制，组装高度碎片化
- 算法差异对连续性影响相对较小

2.2 组装完整性评估

关键发现：wtdbg2 在 CCS 数据上实现近乎完整的基因组组装

质量指标	wtdbg2+CLR	wtdbg2+CCS	hifiasm+CCS
总长度(bp)	1,508,704	4,639,873	4,665,559
参考覆盖度(%)	4.997%	99.943%	100.000%
与参考基因组差异	-3,132,948 bp	-1,779 bp	+23,907 bp

分析：

- wtdbg2+CCS 覆盖度达 99.94%，接近完整组装
- hifiasm+CCS 获得最完整组装，长度略超参考基因组
- wtdbg2+CLR 仅覆盖约 5%，组装严重不完整

2.3 组装准确性比较

关键发现：CCS 数据显著降低碱基错误率

错误类型	wtdbg2 + CLR	wtdbg2 + CCS	hifiasm + CCS
错配(/100kbp)	2,215.23	0.02	0.02
插入缺失(/100kbp)	1,927.46	0.09	0.09
总错误率(/100kbp)	4,142.69	0.11	0.11

分析：

- CCS 数据将错误率降低 37,000 倍
- 两种工具在相同数据上错误率相当
- CLR 数据的高错误率严重影响组装准确性

2.4 计算资源消耗

关键发现：wtdbg2 在保持高质量的同时显著提升计算效率

资源指标	wtdbg2 + CLR	wtdbg2 + CCS	hifiasm + CCS
运行时间	~2 分钟	~2 分钟	~30 分钟
内存需求	~8 GB	~8 GB	>64 GB
CPU 线程	16	16	16

分析：

- wtdbg2 计算效率显著优于 hifiasm
 - 相同工具不同数据资源消耗相当
 - hifiasm 的高资源需求限制其应用场景
-

3. 关键参数与命令

3.1 成功组装的关键参数

● wtdbg2 CLR 组装

```
# wtdbg2组装
echo ""
echo "=== 开始wtdbg2组装 ==="
echo "时间: $(date)"
wtdbg2 -x rs -i CLR.fastq -o clr_wtdbg -t $THREADS

if [ $? -ne 0 ]; then
    echo "错误: wtdbg2组装失败"
    exit 1
fi
```

■ wtdbg2 -x rs -i CLR.fastq -o clr_wtdbg -t 16

● wtdbg2 CCS 组装

```
# 使用 wtdbg2 进行组装
# 修正: 使用 -x ccs 而不是 -x css
echo "步骤1: 运行wtdbg2组装..."
wtdbg2 -x ccs \
    -g $GENOME_SIZE \
    -t $THREADS \
    -i $INPUT_CCS_READS \
    -fo $OUTPUT_PREFIX

# 检查上一步是否成功
if [ ! -f "${OUTPUT_PREFIX}.ctg.lay.gz" ]; then
    echo "错误: wtdbg2组装失败, 未生成 ${OUTPUT_PREFIX}.ctg.lay.gz"
    echo "请检查输入数据和参数设置"
    exit 1
fi

# 生成一致性序列
echo "步骤2: 生成一致性序列..."
wtpoa-cns -t $THREADS \
    -i ${OUTPUT_PREFIX}.ctg.lay.gz \
    -fo ${OUTPUT_PREFIX}.ctg.fa
```

■ wtdbg2 -x ccs -g 4.6m -t 16 -i CCS.fastq -fo ccs_wtdbg_corrected

● hifiasm CCS 组装

```
# hifiasm 组装
echo "步骤1: hifiasm 组装 (使用64GB内存) ..."
hifiasm -t 16 -o ${OUTPUT_PREFIX} $INPUT

# 检查结果
echo "检查生成的hifiasm文件:"
ls -la ${OUTPUT_PREFIX}.* 2>/dev/null || echo "未找到输出文件"

# 转换结果为fasta格式
for gfa_file in ${OUTPUT_PREFIX}.bp.p_ctg.gfa ${OUTPUT_PREFIX}.p_ctg.gfa ${OUTPUT_PREFIX}*.gfa; do
    if [ -f "$gfa_file" ]; then
        echo "找到GFA文件: $gfa_file"
        echo "步骤2: 转换GFA为FASTA..."
        awk '/^S/{print ">"$2"\n"$3}' $gfa_file > ${OUTPUT_PREFIX}_contig.fasta
        break
    fi
done
```

```
hifiasm -t 16 -o ccs_hifiasm CCS.fastq
```

重要: -x ccs 参数的正确使用是 wtdbg2 成功组装 CCS 数据的关键

3.2 参数敏感性分析

参数	正确值	错误值	影响程度
平台类型(-x)	CCS	CSS	关键性
基因组大小(-g)	4.6m	未设置	重要
线程数(-t)	16	默认值	中等

4. 讨论与结论

4.1 主要发现

1. 数据质量的决定性作用

- CCS 数据使 wtdbg2 从失败 (4.19%覆盖度) 变为优秀 (99.94%覆盖度)
- 数据质量提升对组装效果的改善远大于算法优化

2. 工具选择的实用性考量

- 研究场景: hifiasm+CCS (最优质量, 可接受高资源消耗)
- 临床诊断: wtdbg2+CCS (快速准确, 资源需求合理)

- **初步分析**: wtdbg2+CLR (快速经济, 接受碎片化结果)

3. 参数调试的重要性

- 微小参数差异 (`-x ccs` vs `-x css`) 导致截然不同的结果
- 工具文档理解和参数验证是成功的关键步骤

原始数据文件验证:

- `clr\_wtdbg.ctg.fasta`: 1.5 MB, 166 contigs
- `ccs\_wtdbg\_corrected.ctg.fa`: 4.5 MB, 1 contig
- `ccs\_hifiasm\_high\_mem\_contig.fasta`: 4.5 MB, 1 contig

```
(base) [fanxinlan@cu02 genome3]$ ./get_runtime_info.sh
=== 脚本运行时间统计 ===

1. 文件创建时间 (近似运行时间):
-----
clr_wtdbg.ctg.fasta: 2025-11-06 14:03:44.690001401
ccs_wtdbg_corrected.ctg.fa: 2025-11-06 17:00:25.567846072
ccs_hifiasm_high_mem_contig.fasta: 2025-11-06 15:12:31.337632750

2. 脚本文件信息:
-----
-rwxrwxr-x 1 fanxinlan fanxinlan 1756 2025-11-06 16:59:14.092920228 +0800 ccs_wtdbg_promo
h
-rwxrwxr-x 1 fanxinlan fanxinlan 1494 2025-11-06 15:20:02.496799769 +0800 hifiasm_ccs_asm
-rwxrwxr-x 1 fanxinlan fanxinlan 3779 2025-11-06 14:02:39.145996075 +0800 wtdbg2_clr_asm.

3. 输出文件大小对比:
-----
-rw-rw-r-- 1 fanxinlan fanxinlan 4.5M Nov 6 15:12 ccs_hifiasm_high_mem_contig.fasta
-rw-rw-r-- 1 fanxinlan fanxinlan 4.5M Nov 6 17:00 ccs_wtdbg_corrected.ctg.fa
-rw-rw-r-- 1 fanxinlan fanxinlan 1.5M Nov 6 14:03 clr_wtdbg.ctg.fasta
```