

基因组注释实验分析报告

执行摘要

本实验成功建立了真核生物和原核生物的基因组注释流程，完成了从重复序列屏蔽到基因完整性评估的全套分析。关键问题在于拟南芥基因预测的 BUSCO 完整率仅为 15.2%，显著低于预期标准，表明当前注释质量存在严重不足。大肠杆菌注释结果相对可靠，基因数量和结构符合生物学预期。

实验设计与执行

技术环境配置

实验环境基于 Linux 服务器系统，采用 Conda 进行软件管理，确保工具版本一致性和环境隔离。

软件工具配置表：

工具类别	软件名称	版本号	主要功能
重复序列处理	RepeatMasker	4.2.1	基因组重复序列识别与屏蔽
基因结构预测	Augustus	3.5.0	真核生物基因结构预测
完整性评估	BUSCO	6.0.0	基于保守基因的完整性评估
原核基因组注释	Prokka	在线版本	原核生物自动化注释

实验数据集：

物种类型	数据内容	数据规模	数据来源	序列文件
真核生物	拟南芥 4 号染色体	18.58 Mb	TAIR10 数据库	TAIR.chrom4.fa
原核生物	大肠杆菌 K-12 基因组	4.64 Mb	标准参考菌株	Ecoli_genomic.fa

详细实验结果

重复序列分析结果

通过 RepeatMasker 对拟南芥基因组进行重复序列分析，获得以下系统结果：

重复序列统计表：

分析指标	具体数值	生物学意义
基因组总长度	18,584,056 bp	标准染色体规模
重复序列比例	1.88%	低于典型真核基因组
重复序列长度	348,766 bp	需屏蔽处理区域
主要重复类型	简单重复序列	无复杂转座子元件

```
(repeatmasker_env) [fanxinlan@mu01 repeat_masking]$ RepeatMasker -species arabidopsis -xsmall ..TAIR.chrom4.fa -dir .
RepeatMasker version 4.2.1
Search Engine: NCBI/RMBLAST [ 2.14.1+ ]
```

```
Using Master RepeatMasker Database: /d3/scratch/fanxl/miniconda3/envs/repeatmasker_env/share/RepeatMasker/Libraries/famdb
```

```
Title : Dfam
Version : 3.9
Date : 2025-03-10
Families : 166,255
```

```
Species/Taxa Search:
```

```
Arabidopsis [NCBI Taxonomy ID: 3701]
Lineage: root;cellular organisms;Eukaryota;Viridiplantae;
Streptophyta;Streptophytina;Embryophyta;Tracheophyta;
Euphyllophyta;Spermatophyta;Magnoliopsida;Mesangiospermae;
eudicotyledons;Gunneridae;Pentapetalae;rosids;malvids
```

```
Including only curated families:
```

```
9 families in ancestor taxa; 0 lineage-specific families
```

```
(repeatmasker_env) [fanxinlan@mu01 repeat_masking]$ ls
TAIR.chrom4.fa.cat.gz TAIR.chrom4.fa.masked TAIR.chrom4.fa.out TAIR.chrom4.fa.tbl
(repeatmasker_env) [fanxinlan@mu01 repeat_masking]$ cat TAIR.chrom4.fa.tbl
```

```
=====
file name: TAIR.chrom4.fa
sequences: 1
total length: 18584056 bp (18582056 bp excl N/X-runs)
GC level: 36.20 %
bases masked: 348766 bp ( 1.88 %)
```

```
=====
number of      length  percentage
elements*      occupied of sequence
-----
```

Retroelements	0	0 bp	0.00 %
SINEs:	0	0 bp	0.00 %
Penelope:	0	0 bp	0.00 %
LINEs:	0	0 bp	0.00 %
CRE/SLACS	0	0 bp	0.00 %
L2/CR1/Rex	0	0 bp	0.00 %
R1/L0A/Jockey	0	0 bp	0.00 %
R2/R4/NeSL	0	0 bp	0.00 %
RTE/Bov-B	0	0 bp	0.00 %
L1/CIN4	0	0 bp	0.00 %
LTR elements:	0	0 bp	0.00 %
BEL/Pao	0	0 bp	0.00 %
Ty1/Copia	0	0 bp	0.00 %
Gypsy/DIRS1	0	0 bp	0.00 %
Retroviral	0	0 bp	0.00 %
DNA transposons	0	0 bp	0.00 %
hobo-Activator	0	0 bp	0.00 %
Tc1-IS630-Pogo	0	0 bp	0.00 %
En-Spm	0	0 bp	0.00 %
MULE-MuDR	0	0 bp	0.00 %
PiggyBac	0	0 bp	0.00 %
Tourist/Harbinger	0	0 bp	0.00 %
Other (Mirage, P-element, Transib)	0	0 bp	0.00 %
Rolling-circles	0	0 bp	0.00 %
Unclassified:	0	0 bp	0.00 %
Total interspersed repeats:		0 bp	0.00 %
Small RNA:	0	0 bp	0.00 %
Satellites:	0	0 bp	0.00 %

基因预测质量评估

Augustus 基因预测结果显示出明显的质量问题，需要深入分析和优化。

基因预测统计表：

预测特征	数量统计	预期范围	质量评估
总基因数	4,215 个	~1,200 个	严重偏高
转录本数	101,590 个	~1,500 个	异常超高
外显子数	38,715 个	-	需进一步验证
CDS 数目	33,710 个	-	编码区域统计

基因结构特征表：

结构参数	测量值	参考标准	符合度
平均基因长度	2,966.21 bp	2,000-3,000 bp	符合
CDS 平均长度	250.32 bp	200-300 bp	符合
内含子平均长度	181.17 bp	200-500 bp	偏短

```
(augustus_env) [fanxinlan@cu02 augustus_prediction]$ augustus --species=arabidopsis TAIR.chrom4.fa.masked > arabidopsis_chr4_prediction.gff
(augustus_env) [fanxinlan@cu02 augustus_prediction]$ ls
arabidopsis_chr4_prediction.gff  TAIR.chrom4.fa.masked

(base) [fanxinlan@mu01 augustus_prediction]$ echo "转录本数目:" $(grep -c "transcript" arabidopsis_chr4_prediction.gff)
转录本数目: 101590
(base) [fanxinlan@mu01 augustus_prediction]$ echo "mRNA数目:" $(grep -c "mRNA" arabidopsis_chr4_prediction.gff)
mRNA数目: 0
(base) [fanxinlan@mu01 augustus_prediction]$ echo "外显子数目:" $(grep -c "exon" arabidopsis_chr4_prediction.gff)
外显子数目: 38715
(base) [fanxinlan@mu01 augustus_prediction]$ echo "CDS数目:" $(grep -c "CDS" arabidopsis_chr4_prediction.gff)
CDS数目: 33710
(base) [fanxinlan@mu01 augustus_prediction]$ echo "内含子数目:" $(grep -c "intron" arabidopsis_chr4_prediction.gff)
内含子数目: 33545
(base) [fanxinlan@mu01 augustus_prediction]$ echo "总基因数:" $(grep -c "gene" arabidopsis_chr4_prediction.gff)
总基因数: 101594

(base) [fanxinlan@mu01 augustus_prediction]$ awk -F'\t' ' $3=="gene" {len=$5-$4+1; sum+=len; count++; if(len<min)min=len; if(len>max)max=len; if(len<100)c1++; else if(len<500)c2++; else if(len<1000)c3++; else if(len<5000)c4++; else c5++;} END {print "平均长度:", sum/count, "bp"; print "最短基因:", min, "bp"; print "最长基因:", max, "bp"; print ""; print "基因长度分布:"; print " <100bp: ", c1, "个 ("c1/count*100%"); print " 100-500bp:", c2, "个 ("c2/count*100%"); print " 500-1000bp:", c3, "个 ("c3/count*100%"); print " 1-5 kbp: ", c4, "个 ("c4/count*100%"); print " >5kbp: ", c5, "个 ("c5/count*100%")}' arabidopsis_chr4_prediction.gff
平均长度: 2966.21 bp
最短基因: bp
最长基因: 27774 bp

基因长度分布:
<100bp: 0 个 (0%)
100-500bp: 34 个 (0.806643%)
500-1000bp: 418 个 (9.91696%)
1-5kbp: 3184 个 (75.5397%)
>5kbp: 579 个 (13.7367%)

(base) [fanxinlan@mu01 augustus_prediction]$ awk -F'\t' ' $3=="CDS" {sum+= $5-$4+1; count++;} END {print "CDS平均长度:", sum/count, "bp"}' arabidopsis_chr4_prediction.gff
CDS平均长度: 250.318 bp
```


蛋白质序列分析

从预测结果中提取蛋白质序列进行进一步分析：

蛋白质序列统计表：

分析项目	统计结果	数据验证方法
蛋白质序列数量	4,215 条	<pre>(augustus_env) [fanxinlan@cu02 augustus_prediction]\$ grep -c "^>" arabidopsis_chr4_prediction.aa 4215</pre>
总氨基酸数量	2,091,366 个	<pre>(base) [fanxinlan@mu01 augustus_prediction]\$ grep -v ">" arabidopsis_chr4_prediction.aa tr -d '\n' wc -c 2091366</pre>

基因完整性评估

BUSCO 评估结果显示严重的完整性问题，仅 15.2%的保守基因被完整预测。

BUSCO 评估详细结果：

评估类别	基因数量	百分比	质量等级
完整 BUSCOs	245 个	15.2%	严重不足
单拷贝完整	234 个	14.5%	需改进
多拷贝完整	11 个	0.7%	可接受
片段化 BUSCOs	12 个	0.7%	可接受
缺失 BUSCOs	1,357 个	84.1%	严重问题

评估数据库信息：

- 数据库名称：embryophyta_odb10
- 数据库大小：1,614 个保守基因
- 评估模式：蛋白质模式
- 运行时间：369 秒

```
(base) [fanxinlan@mu01 busco_evaluation]$ cat arabidopsis_busco/short_summary.specific.embryophyta_odb10.arabidopsis_busco.txt
# BUSCO version is: 6.0.0
# The lineage dataset is: embryophyta_odb10 (Creation date: 2024-01-08, number of genomes : 50, number of BUSCOs: 1614)
# Summarized benchmarking in BUSCO notation for file /d3/scratch/fanxl/genome4/augustus_prediction/arabidopsis_chr4_prediction.aa
# BUSCO was run in mode: proteins

***** Results: *****

C:15.2%[S:14.5%,D:0.7%],F:0.7%,M:84.1%,n:1614
245   Complete BUSCOs (C)
234   Complete and single-copy BUSCOs (S)
11    Complete and duplicated BUSCOs (D)
12    Fragmented BUSCOs (F)
1357  Missing BUSCOs (M)
1614  Total BUSCO groups searched

Dependencies and versions:
hmmsearch: 3.4
```

大肠杆菌注释结果

大肠杆菌注释结果显示出较好的质量，基因数量和结构符合预期。

原核注释统计表：

注释特征	数量统计	生物学预期	符合程度
基因总数	3,459 个	~4,300 个	基本符合
CDS 数量	4,305 个	-	正常范围
tRNA 数目	159 个	~100-200 个	符合
rRNA 数目	30 个	~20-30 个	符合
基因密度	1 基因/1.34kb	典型原核密度	符合

```
(base) [fanxinlan@mu01 ecoli_proksee]$ echo "基因数目:" $(grep -c "gene" prokka.gff)
基因数目: 3459
(base) [fanxinlan@mu01 ecoli_proksee]$ echo "CDS数目:" $(grep -c "CDS" prokka.gff)
CDS数目: 4305
(base) [fanxinlan@mu01 ecoli_proksee]$ echo "tRNA数目:" $(grep -c "tRNA" prokka.gff)
tRNA数目: 159
(base) [fanxinlan@mu01 ecoli_proksee]$ echo "rRNA数目:" $(grep -c "rRNA" prokka.gff)
rRNA数目: 30
(base) [fanxinlan@mu01 ecoli_proksee]$ echo "tmRNA数目:" $(grep -c "tmRNA" prokka.gff)
tmRNA数目: 2
```

技术对比分析

真核与原核注释差异

通过对比分析，明确了两类生物在注释方法上的本质差异。

技术方法对比表：

技术维度	拟南芥(真核)	大肠杆菌(原核)	差异显著性
重复序列处理	必需步骤	通常省略	高度显著
基因结构复杂度	高(内含子-外显子)	低(连续 ORF)	高度显著
预测工具特异性	专用真核工具	专用原核工具	高度显著
评估标准	BUSCO 保守基因	核心基因集	显著

结果特征对比表：

结果特征	拟南芥结果	大肠杆菌结果	质量差异
基因数量准确性	低	高	明显
结构预测可靠性	待改进	良好	明显
完整性评估	不合格	未评估	需注意

问题诊断与改进方案

问题类别	具体表现	改进方案
参数设置问题	基因预测数量异常	Augustus 参数重新优化，增加预测严格度
模型适配问题	BUSCO 完整率过低	整合多工具预测结果
数据质量问题	转录本数量异常	建立标准化质量控制流程
流程优化问题	缺乏多证据整合	引入 RNA-seq 转录组数据作为外部证据

实验流程以及结果文件：

拟南芥注释流程：

步骤 1：重复序列屏蔽

```
(repeatmasker_env) [fanxinlan@mu01 repeat_masking]$ RepeatMasker -species arabidopsis -xsmall ../TAIR.chrom4.fa -dir .
```

步骤 2：基因结构预测

```
(augustus_env) [fanxinlan@cu02 augustus_prediction]$ augustus --species=arabidopsis TAIR.chrom4.fa.masked > arabidopsis_chr4_prediction.gff
```

步骤 3：蛋白质序列提取

```
(augustus_env) [fanxinlan@cu02 augustus_prediction]$ getAnnoFasta.pl arabidopsis_chr4_prediction.gff
```

步骤 4：完整性评估

```
(busco_env) [fanxinlan@cu02 busco_evaluation]$ busco -i ../augustus_prediction/arabidopsis_chr4_prediction.aa -l embryophyta_odb10 -o arabidopsis_busco -m proteins
```

大肠杆菌注释流程：

使用 Proksee 在线平台的 Prokka 工具进行自动注释。

结果文件：

```
(busco_env) [fanxinlan@mu01 genome4]$ ll *
lrwxrwxrwx 1 fanxinlan fanxinlan 67 Nov 7 19:20 Ecoli_genomic.fa -> /d3/scratch/yinlijuan/04.genome_annotation/01.data/Ecoli_genomic.fa
lrwxrwxrwx 1 fanxinlan fanxinlan 65 Nov 7 19:20 TAIR.chrom4.fa -> /d3/scratch/yinlijuan/04.genome_annotation/01.data/TAIR.chrom4.fa

augustus_prediction:
total 31712
-rw-rw-r-- 1 fanxinlan fanxinlan 2155379 Nov 9 19:16 arabidopsis_chr4_prediction.aa
-rw-rw-r-- 1 fanxinlan fanxinlan 11353579 Nov 9 17:31 arabidopsis_chr4_prediction.gff
-rw-rw-r-- 1 fanxinlan fanxinlan 18955810 Nov 9 16:46 TAIR.chrom4.fa.masked

busco_evaluation:
total 0
drwxrwxr-x 4 fanxinlan fanxinlan 208 Nov 9 19:23 arabidopsis_busco
drwxrwxr-x 4 fanxinlan fanxinlan 82 Nov 9 19:17 busco_downloads

ecoli_proksee:
total 15568
-rw-rw-r-- 1 fanxinlan fanxinlan 9800619 Nov 9 20:11 prokka.gbk
-rw-rw-r-- 1 fanxinlan fanxinlan 5832679 Nov 9 20:11 prokka.gff
-rw-rw-r-- 1 fanxinlan fanxinlan 303352 Nov 9 20:11 prokka.tsv

repeat_masking:
total 20316
-rw-rw-r-- 1 fanxinlan fanxinlan 859725 Nov 9 16:24 TAIR.chrom4.fa.cat.gz
-rw-rw-r-- 1 fanxinlan fanxinlan 18955810 Nov 9 16:24 TAIR.chrom4.fa.masked
-rw-rw-r-- 1 fanxinlan fanxinlan 980384 Nov 9 16:24 TAIR.chrom4.fa.out
-rw-rw-r-- 1 fanxinlan fanxinlan 2442 Nov 9 16:24 TAIR.chrom4.fa.tbl
```